# AgentNexus

## MCP + AI Gateway + A2A 통합 에이전트 플랫폼 PRD

Agent Application/MCP Host · Local Agent Orchestration · AI Gateway 7기능 · A2A Client/Remote Agent · MCP Registry · Identity · Observability & Audit · MCP Servers 5종 · 독립/연계·즉시 사용 플랫폼

작성일: 2026-09-16

출처: 첨부 도식「MCP + AI Gateway + A2A」(Alok Sharan, @alok-sharan, 사용자 제공 이미지) · https://github.com/WisemanLim?tab=stars

저장 위치: /Users/wise/Developer/wise-Analysis-Repos/Need-to-be-organized-into-PRD

# 목차

1. 개요 및 분석 방법
   1.1 배경  1.2 목적  1.3 범위  1.4 대상 독자
2. 참고 자료 및 출처 명시
3. 기준 도식 상세 분석 및 항목 추적표
   3.1 도식 구조 해석  3.2 재구성 도식  3.3 원본 항목 → 요구사항 추적표
4. 목표 시스템 정의
   4.1 시스템명 및 비전  4.2 사용자 및 페르소나  4.3 대표 사용 시나리오
5. 기능 요구사항 (FR)
   5.1 플랫폼 공통  5.2 Agent Application / MCP Host  5.3 AI Gateway
   5.4 LLM Providers  5.5 Remote A2A Agent  5.6 MCP Registry / Catalog
   5.7 Identity & Authorization  5.8 MCP Servers  5.9 Observability & Audit
   5.10 독립 실행 · 연계·연동 · 즉시 사용
6. 비기능 요구사항 (NFR)
7. 시스템 아키텍처
   7.1 계층 아키텍처  7.2 계층·컴포넌트 설명  7.3 요청 처리 시퀀스
8. 기술 스택 및 오픈소스 조사
   8.1 그룹별 오픈소스 카탈로그  8.2 AI 게이트웨이 후보 비교  8.3 1차 선정 스택 요약  8.4 라이선스 위험 분류
9. 데이터 모델 및 API/프로토콜 초안
   9.1 핵심 엔터티
   9.2 프로토콜·API 요약
10. 선택·연계 가이드
11. 평가 지표 및 성공 기준
12. 로드맵 및 마일스톤
13. 리스크 및 대응
부록 A. 용어집
부록 B. 오픈소스·사양 출처·라이선스 총람
부록 C. WisemanLim Star 목록 중 참고 저장소
부록 D. 참고 이미지 출처
부록 E. 조사 방법 및 한계

# 1. 개요 및 분석 방법

| | |
|---|---|
| **출처** | 첨부 도식「MCP + AI Gateway + A2A」(작성자 표기: Alok Sharan, @alok-sharan). 사용자 제공 이미지, 원 게시 URL 미확인 — 부록 D |
| **원자료** | MCP·A2A 공식 SDK/사양/레지스트리, AI 게이트웨이, 에이전트 오케스트레이션, IdP, 관측, 참조 MCP 서버 등 62개 저장소(GitHub REST API, 2026-09-16) + WisemanLim Star 목록 5,826건 교차(35종 일치, 관련 18건 추가) |
| **분석 방법** | 도식 65항목(박스 11그룹·컴포넌트 44·엣지 라벨 13·작성자) 전수 추출 → 요구사항 매핑 → 6계층 아키텍처 → 그룹별 오픈소스 카탈로그 11표·1차 선정·라이선스 4등급 |
| **시스템명** | AgentNexus – MCP + AI Gateway + A2A 통합 에이전트 플랫폼(독립 실행·연계·즉시 사용) |
| **문서 상태** | v0.1 초안(검토 대기) · 작성자 bclim(bclim@edentns.com) · 조사·초안 작성 지원: Claude Code |
| **문서 위치** | /Users/wise/Developer/wise-Analysis-Repos/Need-to-be-organized-into-PRD/AgentNexus_PRD.docx |

### 문서 구성 요약

| 장 | 내용 | 주요 근거 |
|---|---|---|
| 1~2 | 배경·목적·범위, 참고 자료·출처 | 첨부 도식, Star 목록, MCP·A2A 사양 |
| 3 | 도식 구조 해석(11그룹·13엣지), 재구성 도식, 65항목 추적표 | 원본 이미지 전수 분석 |
| 4~6 | 목표 시스템, 플랫폼 공통 FR-P, 그룹별 FR(A·G·L·R·C·I·S·O), 독립/연계 FR-W, NFR | MCP Authorization·A2A 사양, OWASP Agentic |
| 7 | 6계층 아키텍처(그림 2), 컴포넌트, 요청 처리 시퀀스(MCP·A2A·LLM 3경로) | 설계 산출물 |
| 8 | 그룹별 오픈소스 카탈로그 11표(62 저장소), AI 게이트웨이 비교, 1차 선정, 라이선스 4등급 | GitHub API, LICENSE 원문 |
| 9~13 | 데이터 모델·API/프로토콜, 선택·연계 가이드, 평가지표, 로드맵, 리스크 | — |
| 부록 | 용어집, 출처·라이선스 총람, Star 목록 참고 저장소, 이미지 출처, 조사 방법 | — |

## 1.1 배경

에이전트 시스템은 세 가지 연결 문제를 동시에 풀어야 한다. (1) 에이전트가 도구·데이터에 접근하는 표준(MCP), (2) 에이전트가 다른 에이전트와 협업하는 표준(A2A), (3) 이 모든 호출(모델·도구·에이전트)을 단일 지점에서 라우팅·보안·정책·비용 통제하는 AI Gateway. 첨부 도식「MCP + AI Gateway + A2A」(작성자: Alok Sharan)는 사용자 → Agent Application/MCP Host(로컬 오케스트레이션) → AI Gateway → LLM Providers · Remote A2A Agent · MCP Servers 흐름과, 이를 둘러싼 MCP Registry, Identity & Authorization, Observability & Audit을 하나의 그림에 배치한다.

본 PRD는 이 도식의 모든 박스·엣지를 요구사항으로 전개하고, 사용자가 카탈로그에서 MCP 서버·A2A 에이전트·LLM·에이전트 프로파일을 선택·등록하면 즉시 사용할 수 있으며 각 구성요소를 독립 또는 연계·연동으로 운영할 수 있는 자체 호스팅 플랫폼 AgentNexus의 아키텍처·기술 스택·오픈소스를 정의한다.

## 1.2 목적

- **기준 도식의 완전 반영:** 11개 그룹(User, Agent App/MCP Host, LLM Providers, AI Gateway, Remote A2A Agent, Observability & Audit, MCP Registry, Identity & Authorization, MCP Servers, 백엔드 5종, 작성자)과 13개 엣지 라벨(Natural language, Request/Response, Model API calls, Access Tokens, A2A API, Discover servers, MCP Requests, Access Token, Register Metadata, Auth 등)을 추적표(3.3)로 관리.
- **세 프로토콜의 단일 게이트웨이 통합:** MCP(JSON-RPC/Streamable HTTP), A2A(Agent Card/Task/Message), LLM Unified Model API를 AI Gateway가 Routing·Security·Policies·Rate limits·Monitoring·Tool & Agent Governance로 통제.
- **독립/연계·즉시 사용:** 카탈로그 선택 → 등록 → 60초 내 사용. 구성요소 단독(예: MCP 서버만) 또는 연계(Planner→Retriever/Summarize/Executor + 원격 A2A + MCP 도구).
- **오픈소스·라이선스 투명성:** 모든 참고 저장소 GitHub 주소·Star·라이선스 명시, Star 목록 교차(★). 상용 SaaS(OpenAI·Anthropic·Gemini·Entra ID·Okta·Jira·Confluence·Dynatrace)는 SDK 저장소와 자체 호스팅 대안 병기.

## 1.3 범위

**포함 (In-Scope)**

- Agent Application/MCP Host(로컬 오케스트레이션 4 에이전트, MCP Client Layer, A2A Client), AI Gateway 7 기능, LLM 공급자 어댑터, Remote A2A Agent 서버/클라이언트, MCP Registry/Catalog, Identity 연동, Observability & Audit 5 기능, 참조 MCP 서버 5종 + 커스텀 서버 템플릿, 카탈로그·등록·즉시 사용 콘솔

**제외 (Out-of-Scope)**

- LLM 모델 학습, Jira·Confluence·Dynatrace 등 백엔드 SaaS 자체, 특정 클라우드 관리형 게이트웨이 계약

## 1.4 대상 독자

- 에이전트 개발자, 플랫폼 엔지니어, 보안·IAM 담당, 아키텍트, 운영·FinOps 담당

## 2. 참고 자료 및 출처 명시

| 구분 | 자료 | 출처 / 접근 경로 | 비고 |
|---|---|---|---|
| 기준 도식(이미지) | 「MCP + AI Gateway + A2A」 아키텍처 인포그래픽 | 사용자 첨부 이미지. 작성자 표기: Alok Sharan(@alok-sharan) | 원본 저작권은 작성자에게 귀속. 본 문서는 재구성 도식(그림 1)을 사용 |
| 오픈소스 목록 1 | MCP·A2A SDK/사양/레지스트리, AI 게이트웨이, 오케스트레이션, IdP, 관측, 참조 MCP 서버 | 각 공식 GitHub 저장소(부록 B) | Star·라이선스는 2026-09-16 REST API 조회, NOASSERTION은 LICENSE 원문 확인 |
| 오픈소스 목록 2 | GitHub 사용자 WisemanLim의 Star 목록 | https://github.com/WisemanLim?tab=stars (REST API 전체 5,826건) | MCP·A2A·게이트웨이·관측 관련 저장소 교차(★, 부록 C) |
| 사양·표준 | MCP 사양(Authorization, Streamable HTTP, Registry server.json), A2A 사양(Agent Card, Task 상태), OAuth 2.1/RFC 9728/8693, OTel GenAI 컨벤션, OWASP Agentic AI | 부록 B 링크 | 요구사항 근거 |

# 3. 기준 도식 상세 분석 및 항목 추적표

## 3.1 도식 구조 해석

- **진입:** User → 'Natural language' → Agent Application / MCP Host. 사용자는 자연어만 입력하고 나머지는 플랫폼이 처리.
- **Agent Application / MCP Host:** 'Local Agent Orchestration' – Planner Agent가 Retriever·Summarize·Executor 3개 에이전트로 팬아웃하고 결과를 합류. 하단에 MCP Client Layer(도구 접근)와 A2A Client(원격 에이전트 협업) 두 클라이언트. MCP Host = MCP 사양의 호스트 역할(클라이언트 다수 관리).
- **AI Gateway(중심):** Routing, Security, Policies, Rate limits, Monitoring, Unified Model API, Tool & Agent Governance 7기능. 엣지: Agent App ↔ 'Request/Response'; LLM Providers ↔ 'Model API calls'; Remote A2A Agent ↔ 'A2A API'(A2A Client의 빨간 점선도 게이트웨이 경유); MCP Registry ← 'Discover servers'; MCP Servers ← 'MCP Requests JSON-RPC / Streamable HTTP'; Identity ↔ 'Access Token'; Observability ↔ 게이트웨이(보라 점선). 즉 모든 외부 호출이 게이트웨이를 경유하는 허브-스포크.
- **LLM Providers:** OpenAI, Anthropic, Gemini, Domain-Specific Models. 'Access Tokens' 엣지가 LLM Providers와 Remote A2A Agent 사이에 표기 → 원격 에이전트도 토큰으로 모델·API에 접근.
- **Remote A2A Agent:** Agent Card, Messages, Tasks, Streaming, Artifacts – A2A 사양의 5 핵심 개념.
- **MCP Registry / Catalog – 'Discovery only':** 실행 경로가 아닌 발견 전용. MCP Servers → 'Register Metadata', Gateway → 'Discover servers'.
- **Identity & Authorization:** Microsoft Entra ID, Okta. 'Access Token' → Gateway, 'Auth' → MCP Servers(서버 측 인증). 좌측 보라 점선 'Access Token'은 Agent App(MCP Client Layer)이 토큰을 받아 게이트웨이로 전달함을 의미.
- **Observability & Audit:** Tracing, Logs, Metrics, Usage & Cost, Replay & Audit – 게이트웨이와 에이전트 앱을 관통.
- **MCP Servers:** Jira→Jira, Confluence→Confluence API, Internal API→Internal System, Custom→Custom Backend, Dynatrace→Dynatrace API. 5개 서버·5개 백엔드 쌍.
- **보완:** MCP 원격 서버 인증은 MCP Authorization(OAuth 2.1, RFC 9728 Protected Resource Metadata), 게이트웨이의 사용자 대리 호출은 RFC 8693 Token Exchange/OBO로 구현한다.

## 3.2 재구성 도식

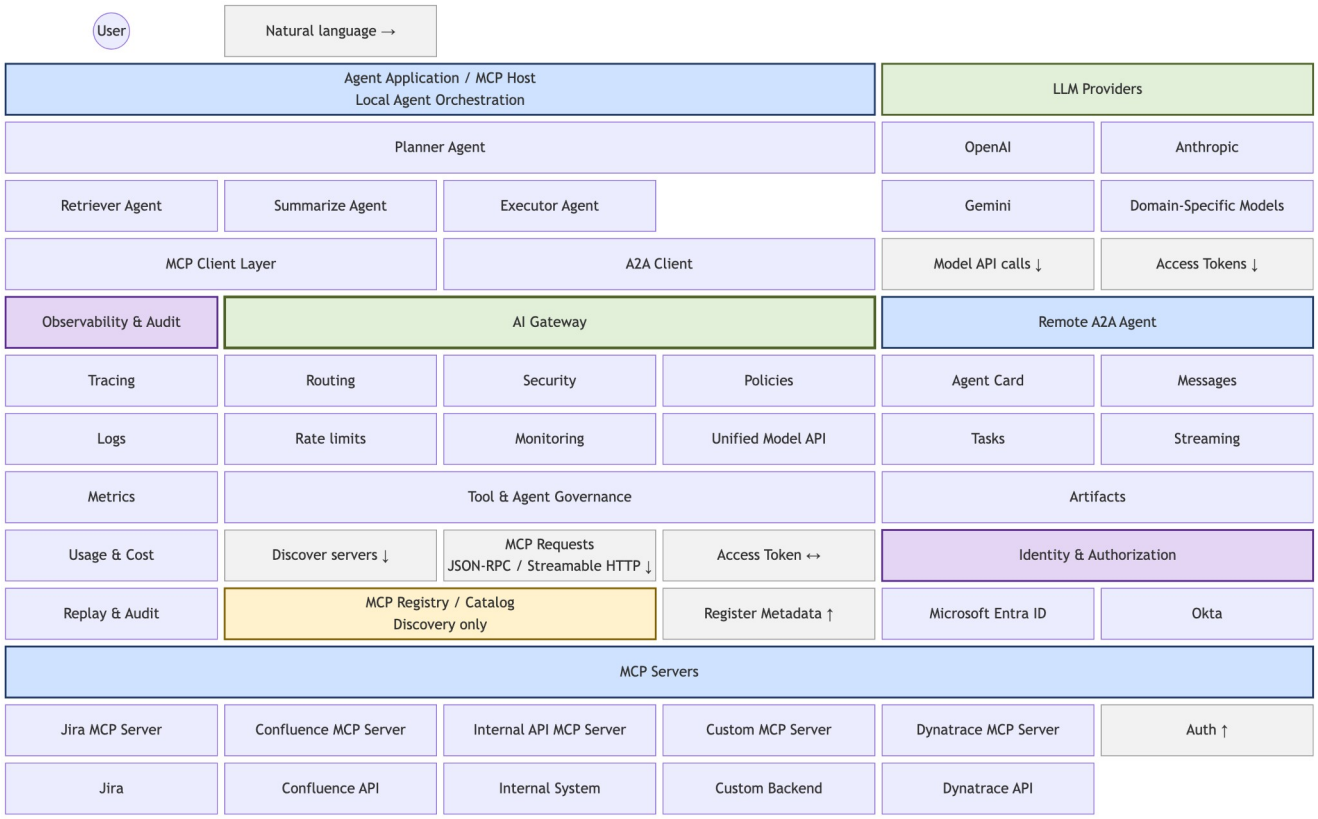



그림 1. 기준 도식 재구성 — 11그룹·44컴포넌트·엣지 라벨(회색 박스) (원본: Alok Sharan, 「MCP + AI Gateway + A2A」 — 사용자 첨부 이미지를 기반으로 재구성, Mermaid block 렌더링)

## 3.3 원본 항목 → 요구사항 추적표 (누락 방지)

원본 항목 총 65개(그룹 라벨 11, 컴포넌트 40, 엣지 라벨 13, 작성자 1).

| ID | 원본 항목(영문 표기 유지) | 해석 | 요구사항 |
|---|---|---|---|
| H01 | 제목: MCP + AI Gateway + A2A | 플랫폼 목적 | FR-P01 |
| U01 | User | 최종 사용자 | FR-A01 |
| E01 | Natural language (User → Agent App) | 자연어 진입 | FR-A01 |
| A00 | Agent Application / MCP Host | 호스트 그룹 | FR-A00 |
| A01 | Local Agent Orchestration | 로컬 오케스트레이션 | FR-A02 |
| A02 | Planner Agent | 계획 에이전트 | FR-A02.1 |
| A03 | Retriever Agent | 검색 에이전트 | FR-A02.2 |
| A04 | Summarize Agent | 요약 에이전트 | FR-A02.3 |
| A05 | Executor Agent | 실행 에이전트 | FR-A02.4 |
| A06 | Planner ↔ 3 Agent 팬아웃/합류 엣지 | 병렬 실행·합류 | FR-A02.5 |
| A07 | MCP Client Layer | MCP 클라이언트 | FR-A03 |
| A08 | A2A Client | A2A 클라이언트 | FR-A04 |
| L00 | LLM Providers | 모델 그룹 | FR-L00 |
| L01 | OpenAI | 상용 LLM | FR-L01 |
| L02 | Anthropic | 상용 LLM | FR-L01 |
| L03 | Gemini | 상용 LLM | FR-L01 |
| L04 | Domain-Specific Models | 도메인 특화 모델 | FR-L02 |

| | | | |
|---|---|---|---|
| E02 | Model API calls (LLM Providers ↔ AI Gateway) | 모델 호출 경유 | FR-G06 |
| E03 | Access Tokens (LLM Providers ↔ Remote A2A Agent) | 원격 에이전트 토큰 | FR-L03, FR-R06 |
| G00 | AI Gateway | 게이트웨이 그룹 | FR-G00 |
| G01 | Routing | 라우팅 | FR-G01 |
| G02 | Security | 보안 | FR-G02 |
| G03 | Policies | 정책 | FR-G03 |
| G04 | Rate limits | 레이트리밋 | FR-G04 |
| G05 | Monitoring | 모니터링 | FR-G05 |
| G06 | Unified Model API | 통합 모델 API | FR-G06 |
| G07 | Tool & Agent Governance | 도구·에이전트 거버넌스 | FR-G07 |
| E04 | Request/Response (Agent App ↔ AI Gateway) | 요청 경유 | FR-G00 |
| E05 | A2A Client ↔ AI Gateway (빨간 점선) | A2A 호출 경유 | FR-A04, FR-G08 |
| E06 | A2A API (AI Gateway ↔ Remote A2A Agent) | A2A 프록시 | FR-G08 |
| E07 | Discover servers (AI Gateway → MCP Registry) | 서버 발견 | FR-C01 |
| E08 | MCP Requests JSON-RPC / Streamable HTTP (AI Gateway → MCP Servers) | MCP 프록시 | FR-G09 |
| E09 | Access Token (AI Gateway ↔ Identity) | 게이트웨이 인증 | FR-I02 |
| E10 | Observability ↔ AI Gateway (보라 점선) | 관측 수집 | FR-O00 |
| E11 | Access Token (Agent App 좌측 보라 점선) | 클라이언트 토큰 전달 | FR-I02 |
| R00 | Remote A2A Agent | 원격 에이전트 그룹 | FR-R00 |
| R01 | Agent Card | 에이전트 카드 | FR-R01 |
| R02 | Messages | 메시지 | FR-R02 |
| R03 | Tasks | 태스크 | FR-R03 |
| R04 | Streaming | 스트리밍 | FR-R04 |
| R05 | Artifacts | 아티팩트 | FR-R05 |
| O00 | Observability & Audit | 관측 그룹 | FR-O00 |
| O01 | Tracing | 트레이싱 | FR-O01 |
| O02 | Logs | 로그 | FR-O02 |
| O03 | Metrics | 메트릭 | FR-O03 |
| O04 | Usage & Cost | 사용량·비용 | FR-O04 |
| O05 | Replay & Audit | 리플레이·감사 | FR-O05 |
| C00 | MCP Registry / Catalog – Discovery only | 발견 전용 레지스트리 | FR-C00 |
| E12 | Register Metadata (MCP Servers → Registry) | 메타데이터 등록 | FR-C02 |
| I00 | Identity & Authorization | 아이덴티티 그룹 | FR-I00 |
| I01 | Microsoft Entra ID | IdP | FR-I01 |
| I02 | Okta | IdP | FR-I01 |
| E13 | Auth (Identity → MCP Servers) | 서버 측 인증 | FR-I03 |
| S00 | MCP Servers | 서버 그룹 | FR-S00 |
| S01 | Jira MCP Server → Jira | 참조 서버 1 | FR-S01 |
| S02 | Confluence MCP Server → Confluence API | 참조 서버 2 | FR-S01 |
| S03 | Internal API MCP Server → Internal System | 참조 서버 3 | FR-S02 |
| S04 | Custom MCP Server → Custom Backend | 참조 서버 4 | FR-S03 |
| S05 | Dynatrace MCP Server → Dynatrace API | 참조 서버 5 | FR-S01 |

| | | | |
|---|---|---|---|
| FT | Alok Sharan @alok-sharan | 출처 표기 | 부록 D |

# 4. 목표 시스템 정의

## 4.1 시스템명 및 비전

**시스템명: AgentNexus – MCP + AI Gateway + A2A 통합 에이전트 플랫폼**

비전: 사용자가 자연어로 요청하면 로컬 오케스트레이션 에이전트들이 계획·검색·요약·실행을 수행하고, 필요한 도구(MCP)·원격 에이전트(A2A)·모델(LLM)은 모두 AI Gateway를 통해 안전하게 호출된다. 관리자는 카탈로그에서 MCP 서버·A2A 에이전트·모델·에이전트 프로파일을 선택·등록하면 즉시 사용할 수 있고, 각 구성요소는 독립 실행 또는 연계·연동으로 운영된다.

## 4.2 사용자 및 페르소나

| 페르소나 | 요구 | 시스템 접점 |
|---|---|---|
| 최종 사용자 | 자연어로 요청하고 Jira·Confluence·내부 시스템 결과를 통합 응답으로 받고 싶다 | 채팅 UI(Natural language), 스트리밍 응답 |
| 에이전트 개발자 | MCP 서버·A2A 에이전트를 만들어 등록하고 오케스트레이션에 끼우고 싶다 | 서버 템플릿(FastMCP·fastapi_mcp), Agent Card 등록, SDK |
| 플랫폼 운영자 | 모델·도구·에이전트 호출을 라우팅·제한·감시하고 비용을 통제하고 싶다 | AI Gateway 콘솔(Routing·Policies·Rate limits·Usage & Cost) |
| 보안·IAM 담당 | Entra ID/Okta 사용자 신원으로 MCP 서버·에이전트 접근을 통제하고 감사하고 싶다 | Identity 연동, Access Token·Auth 흐름, Replay & Audit |
| 외부 파트너 에이전트 | Agent Card로 발견되고 Task를 위임받고 싶다 | A2A API(게이트웨이 경유) |

## 4.3 대표 사용 시나리오

1. 주간 이슈 보고: 사용자 '이번 주 프로젝트 X 이슈 요약해줘' → Planner가 Retriever(Jira MCP 서버 검색)·Summarize(LLM 요약)·Executor(Confluence 페이지 작성) 계획 → MCP Client Layer가 게이트웨이 경유로 MCP Requests → Access Token(Entra ID)으로 Jira/Confluence Auth → 결과 스트리밍.
2. 원격 전문 에이전트 위임: 장애 분석 요청 → A2A Client가 Registry/Agent Card로 '관측 분석 에이전트' 발견 → 게이트웨이 A2A API로 Task 생성 → 원격 에이전트가 Dynatrace MCP 서버·도메인 특화 모델(Access Tokens) 사용 → Artifacts(보고서) 반환.
3. 즉시 사용: 운영자가 카탈로그에서 'Dynatrace MCP Server' 선택 → Register Metadata → 인증 설정(OAuth) → 60초 내 Executor 도구 목록에 노출 → Policies로 읽기 전용 스코프 제한.
4. 비용 통제: Usage & Cost가 팀별 토큰 예산 초과 감지 → Rate limits·Routing이 저비용 모델(vLLM 도메인 모델)로 폴백 → Replay & Audit으로 결정 근거 재현.

# 5. 기능 요구사항 (FR)

우선순위 M(Must)/S(Should)/C(Could). 5.1 플랫폼 공통, 5.2 Agent Application/MCP Host, 5.3 AI Gateway, 5.4 LLM Providers, 5.5 Remote A2A Agent, 5.6 MCP Registry/Catalog, 5.7 Identity & Authorization, 5.8 MCP Servers, 5.9 Observability & Audit, 5.10 독립/연계·즉시 사용.

## 5.1 플랫폼 공통

| ID | 요구사항 | 상세 / 수용 기준 | 우선 | 원본 |
|---|---|---|---|---|
| FR-P01 | 통합 카탈로그·레지스트리 | MCP 서버, A2A 에이전트(Agent Card), LLM 모델/공급자, 에이전트 프로파일(오케스트레이션 템플릿)을 단일 카탈로그에 등록·검색·버전 관리. 선택 → 등록 → 즉시 사용(≤ 60s). | M | H01 |
| FR-P02 | 독립 실행 플랫폼 | 단일 docker compose/Helm로 콘솔·게이트웨이·호스트·레지스트리·IdP(Keycloak)·관측·참조 MCP 서버 전체 기동. 외부 SaaS 없이 동작(로컬 모델·Keycloak·Jaeger). | M | — |
| FR-P03 | 관리 콘솔·API | 카탈로그, 게이트웨이 정책, 인스턴스 상태, 감사 조회. REST/OpenAPI + CLI. | M | — |
| FR-P04 | SBOM·라이선스 리포트 | 선택 구성요소의 SBOM·라이선스 등급(8.4). | S | — |

## 5.2 Agent Application / MCP Host

| ID | 요구사항 | 상세 / 수용 기준 | 우선 | 원본 |
|---|---|---|---|---|
| FR-A00 | MCP Host 역할 | MCP 사양의 Host: 다수 MCP 클라이언트 세션을 생성·관리, 도구·리소스·프롬프트를 에이전트에 노출, 사용자 동의·승인 경계 유지. | M | A00 |
| FR-A01 | 자연어 진입 | 채팅 UI·API로 자연어 요청 수신, 세션·대화 이력, 스트리밍 응답(SSE). 첨부 파일 지원. | M | U01, E01 |
| FR-A02 | Local Agent Orchestration | Planner Agent가 요청을 하위 작업으로 분해·배정, Retriever/Summarize/Executor를 병렬·순차 실행 후 합류. 수용: A02.1 Planner(계획·재계획), A02.2 Retriever(MCP 검색 도구·RAG), A02.3 Summarize(LLM 요약·근거 인용), A02.4 Executor(MCP 쓰기 도구 실행·승인 정책), A02.5 팬아웃/합류·부분 실패 처리. 그래프 정의는 YAML/코드(LangGraph/ADK). | M | A01~A06 |
| FR-A03 | MCP Client Layer | MCP 클라이언트 SDK로 서버 연결(stdio 로컬 / Streamable HTTP 원격 — 원격은 게이트웨이 경유 강제), tools/list·call, resources, prompts, 샘플링 요 | M | A07 |

| | | | | |
|---|---|---|---|---|
| | | 청 처리, 세션 재연결. 수용: 등록된 서버 도구를 Executor/Retriever에서 호출, 호출 전 Tool Governance 정책 통과. | | |
| FR-A04 | A2A Client | a2a-python 클라이언트로 Agent Card 조회, message/send·message/stream, tasks/get·cancel, 푸시 알림 수신. 모든 A2A 호출은 게이트웨이 A2A API 경유. 수용: 원격 에이전트에 Task 위임·Artifacts 수신 E2E. | M | A08, E05 |
| FR-A05 | 플랫폼 에이전트의 A2A 서버 노출 | 로컬 오케스트레이션 자체를 A2A 서버(Agent Card 게시)로 노출해 외부 에이전트가 위임 가능. | S | A00 |

## 5.3 AI Gateway

| ID | 요구사항 | 상세 / 수용 기준 | 우선 | 원본 |
|---|---|---|---|---|
| FR-G00 | 단일 진입 게이트웨이 | Agent App의 모든 외부 호출(모델·MCP·A2A)이 게이트웨이를 경유(Request/Response). 네트워크 정책으로 우회 차단. 프로토콜 인지(LLM HTTP, MCP JSON-RPC/Streamable HTTP, A2A JSON-RPC/SSE). | M | G00, E04 |
| FR-G01 | Routing | 모델 라우팅(비용·지연·품질·가용성 기반, 폴백·재시도·A/B), MCP 서버 라우팅(가상 서버 합성·네임스페이스), A2A 에이전트 라우팅(스킬 기반). 수용: 공급자 장애 시 폴백 성공, 라우팅 결정 로그. | M | G01 |
| FR-G02 | Security | JWT/OAuth2 검증, mTLS, 입력·출력 가드(인젝션·PII), 시크릿 격리(백엔드 API 키는 게이트웨이만 보유). 수용: 미인증 요청 401, 키 유출 0건. | M | G02 |
| FR-G03 | Policies | OPA/Rego 정책: 누가(사용자·에이전트) 어떤 모델·도구·에이전트를 어떤 인자로 호출 가능한지, 데이터 분류별 모델 허용(예: 내부 데이터는 로컬 모델만). 정책 버전·감사. | M | G03 |
| FR-G04 | Rate limits | 사용자·에이전트·팀·모델·도구 단위 요청/토큰/비용 한도, 토큰 버킷(Valkey), 초과 시 429·저비용 폴백. 수용: 한도 초과 차단, 피해 반경 격리. | M | G04 |
| FR-G05 | Monitoring | 게이트웨이 자체 메트릭(QPS·지연·오류·토큰·비용)과 프로토콜별 스팬을 Observability로 전송(OTel). | M | G05, E10 |
| FR-G06 | Unified Model API | OpenAI 호환 단일 엔드포인트로 OpenAI·Anthropic·Gemini· | M | G06, E02 |

| | | | | |
|---|---|---|---|---|
| | | 도메인 특화(vLLM/Ollama) 모델 호출(LiteLLM/Portkey/Bifrost). 스트리밍·도구 호출·구조화 출력 스키마 정규화. 수용: 모델 교체가 클라이언트 코드 변경 없이 설정으로 가능. | | |
| FR-G07 | Tool & Agent Governance | MCP 도구·A2A 에이전트 허용 목록/차단목록, 도구 인자 스키마 검증, 고위험 도구 사람 승인, 에이전트 신뢰 등급, 도구 응답 소독(간접 인젝션), 사용 감사. 수용: 미등록 도구·에이전트 호출 0건 통과. | M | G07 |
| FR-G08 | A2A API 프록시 | 게이트웨이가 원격 A2A 에이전트의 Agent Card를 캐시·검증하고 message/send·stream, tasks 호출을 프록시(인증 헤더 주입·레이트리밋·트레이스). | M | E05, E06 |
| FR-G09 | MCP Requests 프록시 | JSON-RPC / Streamable HTTP MCP 요청을 원격 MCP 서버로 프록시, 세션 관리, 도구 목록 집계(멀티플렉싱), Discover servers로 레지스트리 조회. | M | E07, E08 |

## 5.4 LLM Providers

| ID | 요구사항 | 상세 / 수용 기준 | 우선 | 원본 |
|---|---|---|---|---|
| FR-L00 | 다중 공급자 | OpenAI·Anthropic·Gemini·도메인 특화 모델을 공급자 어댑터로 등록. 모든 호출은 Unified Model API 경유. | M | L00 |
| FR-L01 | 상용 공급자 어댑터 | OpenAI·Anthropic·Gemini SDK 어댑터, 키는 게이트웨이 시크릿 저장소에만, 지역·데이터 처리 옵션 설정. | M | L01~L03 |
| FR-L02 | Domain-Specific Models | vLLM/Ollama로 자체 호스팅 오픈 가중치·미세조정 모델 등록, 정책상 내부 데이터는 로컬 모델 라우팅. | M | L04 |
| FR-L03 | Access Tokens 관리 | 원격 A2A 에이전트·MCP 서버가 모델·API를 호출할 때 사용하는 토큰을 짧은 수명·스코프 제한으로 발급·폐기(IdP 연계). | M | E03 |

## 5.5 Remote A2A Agent

| ID | 요구사항 | 상세 / 수용 기준 | 우선 | 원본 |
|---|---|---|---|---|
| FR-R00 | 원격 에이전트 등록·호출 | 외부/타 프레임워크(ADK·LangGraph·CrewAI 등) A2A 에이전트를 카탈로그에 등록, 게이트웨이 경유 호출. | M | R00 |
| FR-R01 | Agent Card | /.well-known/agent-card.json | M | R01 |

| | | | | |
|---|---|---|---|---|
| | | 조회·검증·캐시: name, description, url, version, capabilities(streaming, pushNotifications), skills, securitySchemes. 카탈로그 검색 인덱스. | | |
| FR-R02 | Messages | message/send(동기)·Part(text/file/data) 처리, 대화 contextId 유지. | M | R02 |
| FR-R03 | Tasks | tasks/get·cancel, 상태 머신(submitted→working→input-required→completed/failed/canceled), 장기 실행 Task는 Temporal로 영속. | M | R03 |
| FR-R04 | Streaming | message/stream(SSE) 및 푸시 알림(webhook) 수신·중계, 부분 결과 UI 표시. | M | R04 |
| FR-R05 | Artifacts | Task 결과 Artifact(파일·데이터·텍스트) 수신·저장·사용자 전달·감사. | M | R05 |
| FR-R06 | 원격 에이전트 인증 | Agent Card securitySchemes에 따라 OAuth2/JWT/API Key 주입, 상호 인증(mTLS) 옵션. | M | E03, E06 |

## 5.6 MCP Registry / Catalog (Discovery only)

| ID | 요구사항 | 상세 / 수용 기준 | 우선 | 원본 |
|---|---|---|---|---|
| FR-C00 | 발견 전용 레지스트리 | 실행 트래픽은 통과하지 않고 메타데이터만 제공. 공식 MCP Registry(server.json 스키마) 자체 호스팅 + Docker MCP Registry 미러링 + 커스텀 항목. | M | C00 |
| FR-C01 | Discover servers | 게이트웨이·콘솔이 레지스트리 API로 서버 검색(이름·태그·도구·인증 방식), 버전·상태 조회. 수용: 등록 서버가 카탈로그에 즉시 노출. | M | E07 |
| FR-C02 | Register Metadata | MCP 서버가 server.json(이름, 전송, 엔드포인트, 도구 목록, 인증 요건, 라이선스)을 등록·갱신, 검증(스키마·서명), 승인 워크플로(운영자 승인 후 공개). | M | E12 |
| FR-C03 | A2A Agent Card 카탈로그 | 동일 카탈로그에 Agent Card 색인(스킬·보안 스킴), MCP 서버와 통합 검색. | S | R01 |

## 5.7 Identity & Authorization

| ID | 요구사항 | 상세 / 수용 기준 | 우선 | 원본 |
|---|---|---|---|---|
| FR-I00 | IdP 연동 | Microsoft Entra ID, Okta 등 외부 IdP를 OIDC로 연동. 자체 호스팅 기본 IdP는 | M | I00~I02 |

| | | | | |
|---|---|---|---|---|
| | | Keycloak(연합 브로커). | | |
| FR-I01 | 사용자 인증 | 콘솔·채팅 UI 로그인(OIDC Authorization Code + PKCE), 세션, 그룹·역할 클레임 동기화. | M | I01, I02 |
| FR-I02 | Access Token 전파 | Agent App이 사용자 Access Token을 게이트웨이에 전달, 게이트웨이는 검증 후 대상(MCP 서버·A2A 에이전트·모델)별 토큰 교환(RFC 8693)/OBO로 최소 스코프 토큰 발급. 수용: 사용자 신원이 백엔드 호출까지 전파·감사. | M | E09, E11 |
| FR-I03 | MCP 서버 Auth | 원격 MCP 서버는 MCP Authorization(OAuth 2.1, Protected Resource Metadata RFC 9728) 준수, 게이트웨이가 인가 서버 메타데이터 발견·토큰 획득, 서버 측 스코프 검증. | M | E13 |
| FR-I04 | 에이전트·서비스 아이덴티티 | 에이전트 인스턴스·MCP 서버는 클라이언트 자격증명(또는 SPIFFE)으로 자체 신원 보유, 사용자 위임 토큰과 분리. | S | E03 |

## 5.8 MCP Servers

| ID | 요구사항 | 상세 / 수용 기준 | 우선 | 원본 |
|---|---|---|---|---|
| FR-S00 | MCP 서버 호스팅 | 참조·커스텀 MCP 서버를 컨테이너로 호스팅(Streamable HTTP), 헬스체크, 레지스트리 자동 등록, 게이트웨이 뒤 배치. | M | S00 |
| FR-S01 | SaaS 연동 서버 (Jira·Confluence·Dynatrace) | mcp-atlassian(Jira·Confluence), dynatrace-mcp를 참조 서버로 제공. 백엔드 인증은 사용자 OAuth 위임 또는 서비스 계정, 스코프 최소화. | M | S01, S02, S05 |
| FR-S02 | Internal API MCP Server | fastapi_mcp/FastMCP로 내부 REST(OpenAPI)를 MCP 도구로 자동 노출, Internal System 인증 연동. | M | S03 |
| FR-S03 | Custom MCP Server 템플릿 | FastMCP 기반 템플릿(도구·리소스·프롬프트, 인증, OTel, server.json 자동 생성), CLI 스캐폴딩·등록. | M | S04 |

## 5.9 Observability & Audit

| ID | 요구사항 | 상세 / 수용 기준 | 우선 | 원본 |
|---|---|---|---|---|
| FR-O00 | 관측 파이프라인 | 게이트웨이·호스트·MCP 서버·A2A 호출을 OpenTelemetry로 계측(GenAI 시맨틱 컨벤션), Collector →백엔드. | M | O00, E10 |
| FR-O01 | Tracing | 사용자 요청 → Planner →하 | M | O01 |

| | | | | |
|---|---|---|---|---|
| | | 위 에이전트 → 게이트웨이 → 모델/MCP/A2A까지 단일 trace_id 전파(W3C Trace Context), Jaeger/Langfuse 조회. | | |
| FR-O02 | Logs | 구조화 로그(요청·정책 결정·오류), PII 마스킹, 보존 정책. | M | O02 |
| FR-O03 | Metrics | QPS·지연·오류율·토큰·도구 호출 수·Task 상태 분포, Prometheus/Grafana 대시보드·알림. | M | O03 |
| FR-O04 | Usage & Cost | 모델·도구·에이전트·팀별 토큰·비용 집계(공급자 단가표), 예산·알림, 게이트웨이 Rate limits 연동. | M | O04 |
| FR-O05 | Replay & Audit | 세션 단위 프롬프트·도구 호출·응답 재생, 불변 감사 로그(해시 체인), 정책 결정 근거 조회, 규제 리포트. | M | O05 |

## 5.10 독립 실행 · 연계·연동 · 즉시 사용

| ID | 요구사항 | 상세 / 수용 기준 | 우선 | 원본 |
|---|---|---|---|---|
| FR-W01 | 구성요소 독립 실행 | AI Gateway만, MCP Registry만, 특정 MCP 서버만, A2A 서버만 단독 기동·사용 가능(프로파일 선언). 예: 게이트웨이를 기존 앱의 LLM 프록시로만 사용. | M | 4항 |
| FR-W02 | 연계(오케스트레이션 조합) | Planner→Retriever/Summarize/Executor 템플릿에 MCP 도구·A2A 에이전트·모델을 드래그/설정으로 결합, 조건·병렬·재시도 정의(LangGraph/ADK 그래프). | M | 4항 |
| FR-W03 | 연동(외부 시스템) | 기존 IdP(Entra ID/Okta), 기존 API 게이트웨이(Kong/APISIX), 기존 관측 스택(Grafana/Jaeger), 외부 MCP 레지스트리·A2A 에이전트와 커넥터로 연동. | M | 4항 |
| FR-W04 | 즉시 사용 | 카탈로그 선택 → 인증 설정 → 정책 기본값 적용 → 60초 내 도구/에이전트/모델이 오케스트레이션과 콘솔에 노출. 사전 템플릿 3종(사내 Q&A, 이슈 보고 자동화, 장애 분석 위임). | M | 4항 |
| FR-W05 | 실패 처리 | 하위 에이전트·도구·원격 Task 실패 시 재시도·폴백·부분 결과 반환, 사용자에게 사유 안내. | M | A06 |

# 6. 비기능 요구사항 (NFR)

| ID | 분류 | 요구사항 | 측정/검증 |
|---|---|---|---|
| NFR-P1 | 성능 | 게이트웨이 추가 지연 p95 ≤ 30ms(정책·라우팅), MCP 도구 호출 프록시 오버헤드 ≤ 20ms, 첫 토큰 스트리밍 ≤ 2s, 카탈로그 등록→사용 ≤ 60s | 부하 테스트(k6) |
| NFR-S1 | 확장성 | 게이트웨이·호스트 무상태 수평 확장, MCP 세션 스티키니스(Valkey), 1천 동시 세션 | 스테이징 |
| NFR-A1 | 가용성 | 게이트웨이 99.95%, 공급자·서버 장애 시 폴백, Task 영속(Temporal) | Chaos 테스트 |
| NFR-SEC1 | 보안 | 모든 외부 호출 게이트웨이 경유(우회 차단), 최소 스코프 토큰 교환, 백엔드 키 게이트웨이 격리, MCP Authorization 준수, 도구 응답 데이터 격리(간접 인젝션) | 네트워크 정책·권한 감사 |
| NFR-SEC2 | 거버넌스 | 도구·에이전트 허용목록 기본 거부, 고위험 도구 사람 승인, OWASP Agentic AI 위협 매핑 | 정책 테스트 |
| NFR-PRV1 | 프라이버시 | 트레이스·로그 PII 마스킹, 데이터 분류별 모델 라우팅(내부 데이터 → 로컬 모델), 개인정보보호법 매핑 | 로그 스캔 |
| NFR-O1 | 관측성 | OTel 100%, 단일 trace_id 전 구간 전파, 비용 집계 정확도 ±2% | 대시보드 검증 |
| NFR-INT1 | 표준 준수 | MCP 사양(최신 릴리스) Streamable HTTP·Authorization, A2A 사양(Agent Card·Task), OpenAI 호환 API, OTel GenAI 컨벤션, server.json 스키마 | 사양 적합성 테스트(MCP Inspector, a2a-samples) |
| NFR-LIC1 | 라이선스 | 허용적 우선. AGPL(Grafana·Tempo·Plane)·ELv2(Phoenix)·ee 디렉터리(LiteLLM·Langfuse)는 분리 배포·미사용. 상용 SaaS는 SDK만 오픈소스임을 표기 | SBOM + ScanCode |
| NFR-M1 | 유지보수 | MCP·A2A 사양 버전 고정·업그레이드 계획(분기), 어댑터로 게이트웨이 구현체 교체 가능 | 계약 테스트 |
| NFR-D1 | 배포 | docker compose / Helm(kgateway·Gateway API), 에어갭(로컬 모델·Keycloak·Jaeger) | CI/CD |

# 7. 시스템 아키텍처

## 7.1 계층 아키텍처

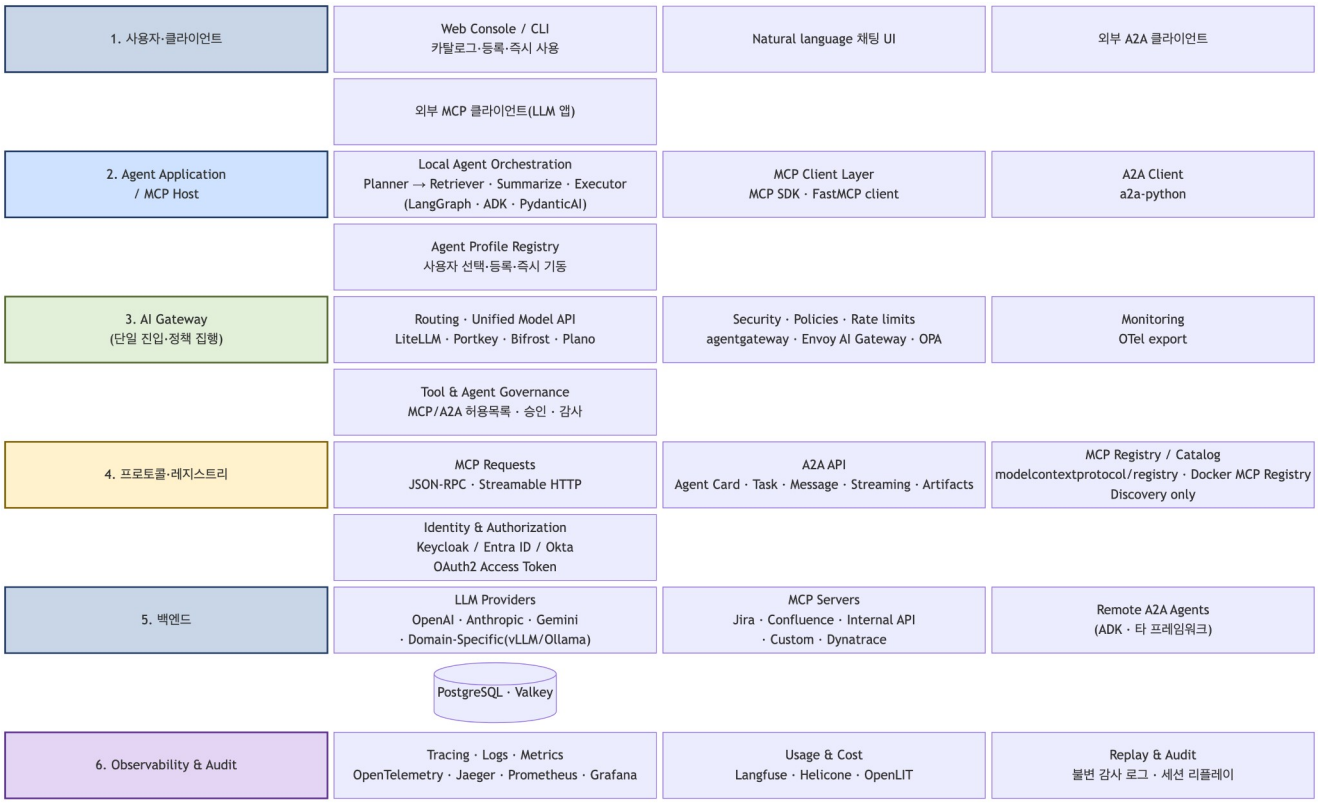



그림 2. AgentNexus 6계층 아키텍처 — 도식의 그룹을 계층·컴포넌트로 배치 (본 문서 작성, Mermaid block 렌더링)

## 7.2 계층·컴포넌트 설명

| 계층 | 컴포넌트(도구) | 책임 | 대응 FR |
|---|---|---|---|
| 1. 사용자·클라이언트 | Web Console/CLI, 자연어 채팅 UI, 외부 A2A·MCP 클라이언트 | 카탈로그·등록·즉시 사용, 자연어 진입 | FR-P01/P03, FR-A01 |
| 2. Agent Application / MCP Host | Local Agent Orchestration(LangGraph·ADK·PydanticAI: Planner·Retriever·Summarize·Executor), MCP Client Layer(MCP SDK·FastMCP), A2A Client(a2a-python), Agent Profile Registry | 계획·병렬 실행·합류, 도구·에이전트 클라이언트 | FR-A00~A05, FR-W02 |
| 3. AI Gateway | Routing·Unified Model API(LiteLLM/Portkey/Bifrost/Plano), Security·Policies·Rate limits(agentgateway·Envoy AI Gateway·OPA·Valkey), Monitoring(OTel), Tool & Agent Governance | 단일 진입·정책 집행·프록시 (LLM·MCP·A2A) | FR-G00~G09 |
| 4. 프로토콜·레지스트리 | MCP(JSON-RPC/Streamable HTTP), A2A(Agent Card·Task·Message·Streaming·Artifacts), MCP Registry(공식 registry·Docker MCP Registry), Identity(Keycloak ↔ Entra ID/Okta, OAuth2 토큰 교환) | 발견·인증·프로토콜 표준 | FR-C00~C03, FR-I00~I04 |

| | | | |
|---|---|---|---|
| 5. 백엔드 | LLM Providers(OpenAI·Anthropic·Gemini·vLLM/Ollama), MCP Servers(Jira·Confluence·Internal API·Custom·Dynatrace), Remote A2A Agents, PostgreSQL·Valkey | 모델·도구·원격 에이전트·저장 | FR-L00~L03, FR-S00~S03, FR-R00~R06 |
| 6. Observability & Audit | OTel Collector, Jaeger·Prometheus·Grafana, Langfuse/Helicone(Usage & Cost·리플레이), 불변 감사 로그 | Tracing·Logs·Metrics·Usage & Cost·Replay & Audit | FR-O00~O05 |

## 7.3 요청 처리 시퀀스 (3경로: LLM · MCP · A2A)

1. User → 채팅 UI: 자연어 요청, OIDC 로그인 세션의 Access Token 첨부
2. Agent App/MCP Host: Planner Agent가 계획 수립(LLM 호출 → 게이트웨이 Unified Model API → Routing으로 모델 선택)
3. Retriever Agent: MCP Client Layer → 게이트웨이 MCP Requests(JSON-RPC/Streamable HTTP) → Tool Governance 허용목록·인자 검증 → 토큰 교환(RFC 8693) → Jira MCP Server(Auth) → 결과 소독 후 반환
4. Summarize Agent: 검색 결과를 LLM 요약(Policies: 내부 데이터는 도메인 특화 로컬 모델로 라우팅)
5. Executor Agent: Confluence 페이지 작성 도구 호출 → 고위험(쓰기) → 사람 승인 → 실행; 또는 A2A Client → 게이트웨이 A2A API → Remote A2A Agent(Agent Card 검증) message/stream → Tasks 상태 추적 → Artifacts 수신
6. 합류 → 스트리밍 응답 → 사용자; 전 구간 단일 trace_id로 Tracing·Logs·Metrics·Usage & Cost 기록, Replay & Audit 저장
7. 레지스트리 경로(비동기): MCP 서버 기동 시 Register Metadata → 운영자 승인 → 게이트웨이 Discover servers → 카탈로그 노출

# 8. 기술 스택 및 오픈소스 조사

조사 방법: 도식 11그룹별 구현 오픈소스를 GitHub REST API로 조회(2026-09-16). NOASSERTION은 LICENSE 원문 확인(MCP 조직 저장소: MIT→Apache-2.0 전환 진행 중; LiteLLM MIT+enterprise/; Langfuse MIT+ee/; Phoenix ELv2; MSAL MIT). 개명 저장소는 현재 이름(envoyproxy/ai-gateway → theagentrouter/agent-router, alibaba/higress → higress-group/higress). ★ = WisemanLim Star 목록 포함.

## 8.1 그룹별 오픈소스 카탈로그

### (a) MCP – SDK·서버 프레임워크·검사 도구 (MCP Host, MCP Client Layer, MCP Servers)

| 도구 | GitHub 저장소 | Star | 라이선스 | 역할 / 대응 항목 |
|---|---|---|---|---|
| MCP Python SDK ★ | modelcontextprotocol/python-sdk | 24,307 | MIT (Apache-2.0 전환 진행 중, LICENSE) | MCP 클라이언트·서버 SDK(stdio·Streamable HTTP, JSON-RPC) |
| MCP TypeScript SDK | modelcontextprotocol/typescript-sdk | 13,404 | MIT (Apache-2.0 전환 진행 중) | TS MCP SDK |
| MCP 참조 서버 ★ | modelcontextprotocol/servers | 90,368 | MIT (Apache-2.0 전환 진행 중) | 공식 참조 MCP 서버 모음 (filesystem, fetch, git 등) |
| MCP Inspector ★ | modelcontextprotocol/inspector | 10,884 | MIT (저장소 LICENSE 확인) | MCP 서버 시각 테스트 도구 |
| FastMCP ★ | PrefectHQ/fastmcp | 27,682 | Apache-2.0 | Python 데코레이터 MCP 서버·클라이언트, 인증(OAuth)·미들웨어·프록시·서버 합성 |
| fastapi_mcp ★ | tadata-org/fastapi_mcp | 12,009 | MIT | FastAPI 엔드포인트 → MCP 도구(인증 포함) – Internal API MCP Server 구현 경로 |
| mcp-use ★ | mcp-use/mcp-use | 10,627 | MIT | 풀스택 MCP 프레임워크(클라이언트·앱) |
| mcp-agent ★ | lastmile-ai/mcp-agent | 8,544 | Apache-2.0 | MCP 기반 에이전트 워크플로 패턴 |

*→ 1차 선정: MCP Python SDK(클라이언트) + FastMCP(서버·인증·프록시) + fastapi_mcp(Internal API 서버) + MCP Inspector(검증).*

### (b) A2A – 사양·SDK (A2A Client, Remote A2A Agent)

| 도구 | GitHub 저장소 | Star | 라이선스 | 역할 / 대응 항목 |
|---|---|---|---|---|
| A2A 프로토콜 ★ | a2aproject/A2A | 25,785 | Apache-2.0 | Agent2Agent 사양: Agent Card, Task, Message, Part/Artifact, Streaming(SSE), Push Notification |
| a2a-python | a2aproject/a2a-python | 2,141 | Apache-2.0 | A2A Python SDK(서버·클라이언트) |
| a2a-js | a2aproject/a2a-js | 617 | Apache-2.0 | A2A JS SDK |
| a2a-samples | a2aproject/a2a-samples | 1,765 | Apache-2.0 | 다중 프레임워크 A2A 샘플 (ADK·LangGraph·CrewAI 등) |

### (c) Local Agent Orchestration – Planner·Retriever·Summarize·Executor

| 도구 | GitHub 저장소 | Star | 라이선스 | 역할 / 대응 항목 |
|---|---|---|---|---|
| Google ADK | google/adk-python | 21,546 | Apache-2.0 | Agent Development Kit – MCP 도구·A2A 서버/클라이언트 네이티브, 멀티 에이전트(Sequential/Parallel/Loop) |
| OpenAI Agents SDK ★ | openai/openai-agents-python | 29,466 | MIT | 핸드오프·가드레일·MCP 서버 통합 에이전트 SDK |
| Microsoft Agent Framework | microsoft/agent-framework | 13,536 | MIT | AutoGen+Semantic Kernel 통합 |

| | | | | |
|---|---|---|---|---|
| | | | | 프레임워크, A2A·MCP 지원 |
| LangGraph ★ | langchain-ai/langgraph | 41,713 | MIT | 상태 그래프 오케스트레이션 (Planner→병렬 에이전트→합류), 체크포인트, interrupt |
| CrewAI ★ | crewAIInc/crewAI | 58,621 | MIT | 역할 기반 멀티 에이전트 (Planner·Retriever·Summarizer·Executor 역할 매핑) |
| AutoGen ★ | microsoft/autogen | 61,001 | MIT (코드) / CC-BY-4.0 (문서) | 이벤트 기반 멀티 에이전트 |
| PydanticAI ★ | pydantic/pydantic-ai | 19,967 | MIT | 타입 안전 에이전트, MCP 클라이언트·A2A 노출 지원 |

*→ 1차 선정: LangGraph(상태 그래프·병렬 팬아웃·체크포인트·승인 interrupt) 또는 Google ADK(MCP·A2A 네이티브). 역할 기반 표현이 필요하면 CrewAI.*

### (d) AI Gateway – Routing · Unified Model API · Rate limits

| 도구 | GitHub 저장소 | Star | 라이선스 | 역할 / 대응 항목 |
|---|---|---|---|---|
| LiteLLM ★ | BerriAI/litellm | 58,820 | MIT (enterprise/ 별도) | 100+ LLM 공급자 OpenAI 호환 프록시: 라우팅·폴백·레이트리밋·예산·키 관리·로깅 |
| Portkey Gateway ★ | Portkey-AI/gateway | 13,003 | MIT | 1,600+ 모델 라우팅, 가드레일 50+, 캐시·재시도 |
| Bifrost ★ | maximhq/bifrost | 8,099 | Apache-2.0 | 고성능 Go AI 게이트웨이, 거버넌스·MCP 게이트웨이 기능 |
| Plano ★ | katanemo/plano | 7,051 | Apache-2.0 | 에이전트용 AI 네이티브 데이터 플레인(라우팅·관측·에이전트 오케스트레이션) |
| TensorZero ★ | tensorzero/tensorzero | 11,720 | Apache-2.0 | LLM 게이트웨이+관측+최적화 통합 |
| Higress | higress-group/higress | 9,389 | Apache-2.0 | Envoy 기반 AI 게이트웨이(MCP 서버 호스팅·라우팅) |
| Apache APISIX | apache/apisix | 17,125 | Apache-2.0 | API 게이트웨이(ai-proxy·ai-rate-limiting 플러그인) |
| Kong | Kong/kong | 44,141 | Apache-2.0 | API 게이트웨이(AI Gateway 플러그인: ai-proxy·ai-prompt-guard) |

### (e) AI Gateway – Security · Policies · Tool & Agent Governance (MCP/A2A 데이터 플레인)

| 도구 | GitHub 저장소 | Star | 라이선스 | 역할 / 대응 항목 |
|---|---|---|---|---|
| agentgateway | agentgateway/agentgateway | 4,869 | Apache-2.0 | MCP·A2A 전용 데이터 플레인: 인증(JWT/OAuth)·RBAC·레이트리밋·멀티플렉싱·OTel |
| kgateway | kgateway-dev/kgateway | 5,689 | Apache-2.0 | Kubernetes Gateway API 구현 (Envoy), agentgateway 통합 |
| Envoy AI Gateway (agent-router) | theagentrouter/agent-router | 2,099 | Apache-2.0 | Envoy 기반 AI/에이전트 라우터. 구 envoyproxy/ai-gateway |
| MCP Context Forge | IBM/mcp-context-forge | 4,477 | Apache-2.0 | IBM MCP 게이트웨이·레지스트리(가상 서버 합성, 인증, 관측) |
| MCP Gateway (Lasso) | lasso-security/mcp-gateway | 387 | MIT | MCP 트래픽 보안 플러그인 게이트웨이(PII·시크릿 마스킹) |
| Agent Governance Toolkit ★ | microsoft/agent-governance-toolkit | 6,268 | MIT | 정책 집행·제로트러스트 아이덴티티·실행 샌드박스 |
| OPA | open-policy-agent/opa | 12,238 | Apache-2.0 | 정책 엔진(Rego) – Policies·Tool & Agent Governance 판정 |

*→ 1차 선정: agentgateway(MCP·A2A 데이터 플레인: 인증·RBAC·레이트리밋·멀티플렉싱·OTel) + LiteLLM(Unified Model API·비용·폴백) + OPA(Policies). Kubernetes는 kgateway(Gateway API)로 통합. 대안: Bifrost(단일 바이너리로 LLM+MCP 게이트웨이).*

### (f) MCP Registry / Catalog

| 도구 | GitHub 저장소 | Star | 라이선스 | 역할 / 대응 항목 |
|---|---|---|---|---|
| MCP Registry (공식) | modelcontextprotocol/registry | 7,254 | MIT (Apache-2.0 전환 진행 중) | 공식 MCP 서버 레지스트리 (server.json 메타데이터, 발견 API). 자체 호스팅 가능 |
| Docker MCP Registry | docker/mcp-registry | 554 | MIT | Docker MCP 카탈로그(컨테이너 이미지 기반 서버 목록) |
| awesome-mcp-servers ★ | punkpeye/awesome-mcp-servers | 95,055 | MIT | 커뮤니티 MCP 서버 큐레이션 |

*→ 1차 선정: 공식 MCP Registry 자체 호스팅(server.json) + Docker MCP Registry 미러 + Agent Card 색인 확장.*

### (g) LLM Providers

| 도구 | GitHub 저장소 | Star | 라이선스 | 역할 / 대응 항목 |
|---|---|---|---|---|
| OpenAI SDK ★ | openai/openai-python | 31,626 | Apache-2.0 | OpenAI API(상용) |
| Anthropic SDK | anthropics/anthropic-sdk-python | 3,902 | MIT | Claude API(상용) |
| Google GenAI SDK ★ | googleapis/python-genai | 3,978 | Apache-2.0 | Gemini API(상용) |
| vLLM ★ | vllm-project/vllm | 91,866 | Apache-2.0 | 도메인 특화·오픈 가중치 모델 서빙(OpenAI 호환) |
| Ollama ★ | ollama/ollama | 181,079 | MIT | 로컬 모델 실행(OpenAI 호환) |

### (h) Identity & Authorization

| 도구 | GitHub 저장소 | Star | 라이선스 | 역할 / 대응 항목 |
|---|---|---|---|---|
| Keycloak ★ | keycloak/keycloak | 36,793 | Apache-2.0 | 자체 호스팅 IdP(OIDC·OAuth2·SAML). Entra ID/Okta 연합 브로커 |
| Ory Hydra | ory/hydra | 17,543 | Apache-2.0 | 헤드리스 OAuth2/OIDC 서버(토큰 교환·인트로스펙션) |
| Authlib | authlib/authlib | 5,422 | BSD-3-Clause | Python OAuth2/OIDC 클라이언트·서버, MCP Authorization 구현 보조 |
| MSAL for Python | AzureAD/microsoft-authentication-library-for-python | 972 | MIT | Microsoft Entra ID 토큰 획득 (OBO·클라이언트 자격증명) |
| Okta SDK | okta/okta-sdk-python | 270 | Apache-2.0 | Okta 관리 API SDK |

*→ 1차 선정: Keycloak(자체 IdP·Entra ID/Okta 연합 브로커·토큰 교환) + Authlib(MCP Authorization 클라이언트). Entra ID/Okta는 상용 SaaS → OIDC 연합.*

### (i) Observability & Audit

| 도구 | GitHub 저장소 | Star | 라이선스 | 역할 / 대응 항목 |
|---|---|---|---|---|
| OpenTelemetry | open-telemetry/opentelemetry-python | 2,633 | Apache-2.0 | Tracing·Logs·Metrics 표준(GenAI 시맨틱 컨벤션) |
| OpenLLMetry | traceloop/openllmetry | 7,430 | Apache-2.0 | LLM·에이전트 프레임워크 OTel 자동 계측 |
| OpenLIT | openlit/openlit | 2,768 | Apache-2.0 | OTel 네이티브 LLM 관측(비용·GPU) |

| | | | | |
|---|---|---|---|---|
| Jaeger ★ | jaegertracing/jaeger | 23,211 | Apache-2.0 | 분산 트레이싱 백엔드 |
| Prometheus ★ | prometheus/prometheus | 66,081 | Apache-2.0 | 메트릭 |
| Grafana ★ | grafana/grafana | 76,766 | AGPL-3.0 | 대시보드. AGPL |
| Langfuse | langfuse/langfuse | 34,654 | MIT (ee/ 별도) | LLM 트레이싱·Usage & Cost·세션 리플레이·평가 |
| Helicone ★ | Helicone/helicone | 6,159 | Apache-2.0 | LLM 관측·비용·요청 리플레이 |
| Arize Phoenix ★ | Arize-ai/phoenix | 11,474 | Elastic License 2.0 | OTLP 기반 LLM 관측·평가 |
| Opik ★ | comet-ml/opik | 22,046 | Apache-2.0 | LLM/에이전트 평가·모니터링 |

*→ 1차 선정: OTel + OpenLLMetry(자동 계측) → Jaeger(Tracing)·Prometheus/Grafana(Metrics) + Langfuse(Usage & Cost·세션 리플레이). Grafana는 AGPL 분리 배포.*

### (j) 참조 MCP 서버 — Jira · Confluence · Dynatrace · 원격 서버 패턴

| 도구 | GitHub 저장소 | Star | 라이선스 | 역할 / 대응 항목 |
|---|---|---|---|---|
| mcp-atlassian ★ | sooperset/mcp-atlassian | 5,906 | MIT | Jira·Confluence MCP 서버 (Cloud/Server/DC) – 도식 Jira/Confluence MCP Server 대응 |
| Dynatrace MCP | dynatrace-oss/dynatrace-mcp | 136 | MIT | Dynatrace 공식 MCP 서버 — 도식 Dynatrace MCP Server 대응 |
| GitHub MCP Server ★ | github/github-mcp-server | 32,956 | MIT | GitHub 공식 원격 MCP 서버 (OAuth) – Custom/원격 서버 참조 |
| AWS MCP Servers ★ | awslabs/mcp | 9,696 | Apache-2.0 | AWS 서비스 MCP 서버 모음 |

### (k) 플랫폼 공통

| 도구 | GitHub 저장소 | Star | 라이선스 | 역할 / 대응 항목 |
|---|---|---|---|---|
| FastAPI ★ | fastapi/fastapi | 102,354 | MIT | 플랫폼 API·콘솔 백엔드 |
| Valkey | valkey-io/valkey | 27,207 | BSD-3-Clause | 세션·레이트리밋 카운터·큐 |
| Temporal | temporalio/temporal | 23,069 | MIT | 장기 실행 Task·재시도(A2A Task 상태 머신 백엔드) |

## 8.2 AI 게이트웨이 후보 비교

| 후보 | LLM 라우팅 | MCP 프록시 | A2A 프록시 | 정책·인증 | 관측 | 라이선스·비고 |
|---|---|---|---|---|---|---|
| agentgateway + LiteLLM | LiteLLM(100+ 공급자) | 네이티브(멀티플렉싱) | 네이티브 | JWT/OAuth·RBAC·레이트리밋 + OPA | OTel 내장 | Apache-2.0 / MIT(ee 제외). 1차 선정 |
| Bifrost | 네이티브(Go, 고성능) | MCP 게이트웨이 기능 | — | 거버넌스·예산 | 내장 | Apache-2.0. 단일 바이너리 대안 |
| Portkey Gateway | 1,600+ 모델 | MCP 지원(일부) | — | 가드레일 50+ | 내장 | MIT |
| Plano | 스마트 라우팅 | 에이전트 오케스트레이션 | — | 가드레일 | OTel | Apache-2.0 |
| Kong / APISIX | AI 플러그인 | 제한적 | — | 성숙한 API 정책 | 플러그인 | Apache-2.0. 기존 API GW 보유 시 |
| Higress | AI 라우팅 | MCP 서버 호스팅 | — | Envoy/Istio 정책 | 내장 | Apache-2.0 |
| MCP Context Forge | — | 가상 서버 합성·레지스트리 | A2A 통합(일부) | 인증·RBAC | 내장 | Apache-2.0. MCP 특화 |

## 8.3 1차 선정 스택 요약 (Reference Stack)

| 항목 | 선정 | 대안 | 라이선스 |
|---|---|---|---|
| Agent App / MCP Host | Python 3.12 + LangGraph ★(Planner·Retriever·Summarize·Executor 그래프) + MCP Python SDK ★ + a2a-python | Google ADK(MCP·A2A 네이티브), PydanticAI ★ | MIT / Apache-2.0 |
| AI Gateway – LLM | LiteLLM ★ Unified Model API(라우팅·폴백·예산) | Bifrost ★, Portkey ★ | MIT(ee 제외) |
| AI Gateway – MCP·A2A | agentgateway(인증·RBAC·레이트리밋·멀티플렉싱) | Bifrost ★, MCP Context Forge | Apache-2.0 |
| Policies | OPA(Rego) – 모델·도구·에이전트 허용, 데이터 분류 라우팅 | Cerbos | Apache-2.0 |
| Rate limits | agentgateway/LiteLLM 한도 + Valkey | Envoy rate limit | BSD-3 |
| Tool & Agent Governance | agentgateway RBAC + OPA + 승인(LangGraph interrupt) + Agent Governance Toolkit ★ 참고 | Lasso MCP Gateway(마스킹) | MIT / Apache-2.0 |
| MCP Registry | 공식 MCP Registry 자체 호스팅 + Docker MCP Registry 미러 | MCP Context Forge 레지스트리 | MIT→Apache-2.0 |
| Identity | Keycloak ★(OIDC 연합: Entra ID·Okta) + 토큰 교환(RFC 8693) + Authlib | Ory Hydra | Apache-2.0 / BSD-3 |
| LLM Providers | OpenAI·Anthropic·Gemini SDK + vLLM ★/Ollama ★(도메인 특화) | — | Apache-2.0 / MIT |
| MCP Servers | mcp-atlassian ★(Jira·Confluence) + dynatrace-mcp + fastapi_mcp ★(Internal API) + FastMCP ★ 템플릿(Custom) | GitHub MCP Server ★ 패턴 | MIT / Apache-2.0 |
| Remote A2A Agent | a2a-python 서버 + Temporal(장기 Task) | ADK A2A 서버 | Apache-2.0 / MIT |
| Observability | OTel + OpenLLMetry →Jaeger ★ · Prometheus ★ · Grafana ★ + Langfuse(Usage & Cost·Replay) | Phoenix ★(ELv2), Helicone ★, Opik ★ | Apache-2.0 / MIT+ee / AGPL(분리) |
| 플랫폼 | FastAPI ★ 콘솔 API, PostgreSQL, Valkey, docker compose/Helm(kgateway) | — | MIT / PostgreSQL / BSD-3 |

## 8.4 라이선스 위험 분류

| 등급 | 라이선스 | 해당 도구 | 정책 |
|---|---|---|---|
| 낮음(허용적) | MIT, Apache-2.0, BSD | MCP SDK·참조 서버·Registry·Inspector(MIT→Apache 전환), FastMCP, fastapi_mcp, A2A 전체, ADK, OpenAI Agents SDK, Agent Framework, LangGraph, CrewAI, AutoGen(코드), PydanticAI, Portkey, Bifrost, Plano, TensorZero, Higress, APISIX, Kong, agentgateway, kgateway, agent-router, MCP Context Forge, Lasso MCP Gateway, Agent Governance Toolkit, OPA, Docker MCP Registry, awesome-mcp-servers, 공급자 SDK, vLLM, Ollama, Keycloak, Hydra, Authlib, MSAL, Okta SDK, OTel, OpenLLMetry, OpenLIT, Jaeger, Prometheus, Helicone, Opik, mcp-atlassian, dynatrace-mcp, GitHub MCP Server, AWS MCP, FastAPI, Valkey, Temporal | 채택 가능. NOTICE 유지. MCP 조직 저장소는 전환 중이므로 채택 시점 LICENSE 재확인 |

| | | | |
|---|---|---|---|
| 중간(조건부) | MIT/Apache + enterprise·ee 디렉터리, ELv2, SDK만 오픈소스인 상용 SaaS | LiteLLM(enterprise/), Langfuse(ee/), Phoenix(ELv2); OpenAI·Anthropic·Gemini·Entra ID·Okta·Jira·Confluence·Dynatrace(서비스 상용) | ee 디렉터리 미사용, SaaS 의존 목록화·데이터 반출 검토, 자체 호스팅 대안(vLLM·Keycloak·Plane) 병기 |
| 높음(카피레프트) | AGPL-3.0 | Grafana, Grafana Tempo, Plane(Jira 대안) | 미수정·분리 배포, 재배포·SaaS 제공 시 법무 검토 |
| 유지보수 리스크 | — | MCP·A2A 사양 급변(Authorization·Streamable HTTP 개정), 저장소 개명(envoyproxy/ai-gateway→agent-router, archgw→plano) | 버전 고정, 분기 재조사, 어댑터 격리 |

# 9. 데이터 모델 및 API/프로토콜 초안

## 9.1 핵심 엔터티

| 엔터티 | 주요 필드 | 비고 |
|---|---|---|
| CatalogItem | id, type(mcp_server\|a2a_agent\|model\|agent_profile), name, description, source(registry\|manual), metadata(server.json \| agent-card.json \| provider), auth_scheme, status(pending\|approved\|active), version, license | FR-P01, FR-C00~C03 |
| McpServer | server_json(name, transport, endpoint, tools[], resources[], prompts[]), auth(oauth_metadata_url, scopes), health, owner | FR-S00, FR-C02 |
| A2AAgentCard | name, url, version, capabilities{streaming, pushNotifications}, skills[], securitySchemes, trust_tier | FR-R01 |
| AgentProfile | id, graph(LangGraph/ADK 정의: planner, workers[retriever, summarize, executor]), tools[], remote_agents[], models[], policies[] | FR-A02, FR-W02 |
| GatewayPolicy | id, subject(user\|group\|agent), target(model\|tool\|agent), allow/deny, args_schema, rate_limit{rps, tokens, budget}, data_class_routing, approval_required | FR-G03/G04/G07 |
| Session / Task | session_id, user_id, trace_id, messages[], a2a_tasks[{task_id, remote_agent, state, artifacts[]}], tool_calls[] | FR-A01, FR-R03 |
| TokenExchange | user_token_ref, audience(mcp_server\|agent\|model), scopes, issued_at, ttl | FR-I02 |
| UsageRecord | ts, session_id, agent, model\|tool\|remote_agent, tokens_in/out, cost, latency, policy_decisions[] | FR-O04 |
| AuditEvent | event_id, ts, actor, action, target, decision, trace_id, prev_hash | FR-O05 |

## 9.2 프로토콜·API 요약

### 게이트웨이 엔드포인트

POST /v1/chat/completions (Unified Model API, OpenAI 호환) · POST /mcp/{server_id} (JSON-RPC over Streamable HTTP: initialize, tools/list, tools/call, resources/read) · POST /a2a/{agent_id} (JSON-RPC: message/send, message/stream, tasks/get, tasks/cancel) · GET /.well-known/agent-card.json (플랫폼 에이전트 카드)

### 레지스트리·카탈로그

GET /v0/servers?search= · GET /v0/servers/{id} · POST /v0/publish (server.json) · GET /v1/catalog?type= · POST /v1/catalog/{id}/register → instance · POST /v1/catalog/{id}/approve

### server.json 예(Internal API MCP Server)

```
{
  "name": "io.agentnexus/internal-api",
  "description": "Internal System REST → MCP tools",
  "version": "0.1.0",
  "remotes": [{"type": "streamable-http", "url": "https://gw.internal/mcp/internal-api"}],
  "packages": [],
  "_meta": {"auth": {"type": "oauth2", "resource_metadata": "https://gw.internal/.well-known/oauth-
protected-resource"},
            "tools": ["orders.search", "orders.get", "tickets.create"], "license": "MIT"}
}
```

**정책 예(OPA Rego) – 데이터 분류별 모델 라우팅 + 도구 승인**

```
package agentnexus.gateway


default allow := false


allow if {
  input.kind == "model"
  input.data_class == "internal"
  input.model in {"vllm/domain-7b", "ollama/qwen"}
}


allow if {
  input.kind == "tool"
  input.tool in data.agents[input.agent].allowed_tools
  not high_risk
}


require_approval if {
  input.kind == "tool"
  input.tool in {"confluence.create_page", "jira.transition_issue"}
}
high_risk if require_approval
```

# 10. 선택·연계 가이드

| 상황 | 권장 구성 | 비고 |
|---|---|---|
| 기존 앱에 LLM 프록시만 필요 | AI Gateway(LiteLLM) 단독 + Observability | FR-W01 독립 실행 |
| 사내 SaaS 도구를 에이전트에 연결 | MCP Registry + mcp-atlassian/dynatrace-mcp + agentgateway + Keycloak 토큰 교환 | Auth·Access Token 흐름 필수 |
| 내부 REST를 도구화 | fastapi_mcp로 Internal API MCP Server →Register Metadata | OpenAPI 재사용 |
| 여러 팀 에이전트 협업 | A2A Client/Server + Agent Card 카탈로그 + 게이트웨이 A2A API | Task 영속은 Temporal |
| 데이터 반출 금지 | Domain-Specific Models(vLLM/Ollama) + Policies 데이터 분류 라우팅 + Keycloak | 에어갭 프로파일 |
| 비용 통제 | Usage & Cost(Langfuse/LiteLLM) + Rate limits 예산 + 저비용 폴백 라우팅 | FR-G01/G04/O04 |
| 규제·감사 | Replay & Audit 불변 로그 + 정책 결정 로그 + IdP 신원 전파 | FR-O05, FR-I02 |

# 11. 평가 지표 및 성공 기준

| 구분 | 지표 | 목표(MVP) | 측정 |
|---|---|---|---|
| 완전성 | 도식 11그룹·44컴포넌트 구현·계약 테스트 | 100% | CI |
| 즉시 사용 | 카탈로그 선택→사용 가능 | ≤ 60s | CI 타이밍 |
| 표준 적합성 | MCP Inspector 검증, a2a-samples 상호운용, OpenAI 호환 API 테스트 | 통과 | 적합성 테스트 |
| 보안 | 게이트웨이 우회 경로, 미허용 도구 통과, 백엔드 키 노출 | 각 0건 | 네트워크·권한 테스트 |
| 성능 | 게이트웨이 오버헤드 p95, 첫 토큰 | ≤ 30ms, ≤ 2s | k6 |
| 관측 | trace_id 전 구간 전파율, 비용 집계 오차 | 100%, ±2% | OTel 검증 |
| 연계 | 템플릿 3종(사내 Q&A, 이슈 보고, 장애 분석 위임) E2E | 100% | E2E 테스트 |

## 12. 로드맵 및 마일스톤

| 단계 | 기간(안) | 범위 | 완료 기준 |
|---|---|---|---|
| Phase 0 – 기반 | 3주 | 카탈로그·레지스트리(공식 MCP Registry), Keycloak, OTel 파이프라인, compose | 빈 카탈로그 등록→발견 E2E |
| Phase 1 – MCP 경로 | 5주 | MCP Host/Client Layer, agentgateway MCP 프록시, fastapi_mcp Internal API 서버, mcp-atlassian, 토큰 교환·MCP Authorization | Jira/Confluence 도구 호출 E2E, 우회 0건 |
| Phase 2 – LLM 경로·오케스트레이션 | 5주 | LiteLLM Unified Model API, Routing·Rate limits·Policies(OPA), Planner→Retriever/Summarize/Executor (LangGraph), 도메인 모델(vLLM) | 이슈 보고 템플릿 E2E, 폴백·예산 테스트 |
| Phase 3 – A2A 경로 | 4주 | A2A Client/Server, Agent Card 카탈로그, 게이트웨이 A2A API, Tasks·Streaming·Artifacts, Temporal | 장애 분석 위임 템플릿 E2E, a2a-samples 상호운용 |
| Phase 4 – 관측·거버넌스·운영화 | 4주 | Usage & Cost, Replay & Audit, Tool & Agent Governance 승인, Helm(kgateway), SBOM | NFR 충족, v1.0 |

# 13. 리스크 및 대응

| 리스크 | 영향 | 대응 |
|---|---|---|
| MCP·A2A 사양 급변(Authorization·전송·Registry 스키마) | 호환성 파손 | SDK·사양 버전 고정, 어댑터 계층, 분기 업그레이드 계획 |
| 게이트웨이 단일 장애점·지연 | 전체 중단·UX 저하 | 다중 인스턴스, 폴백, 캐시, 경로별 SLO |
| 도구 응답을 통한 간접 인젝션·과도한 에이전시 | 오작동·데이터 유출 | Tool Governance 소독·허용목록·승인, 데이터 분류 라우팅 |
| 상용 SaaS(IdP·모델·Jira 등) 종속·비용 | 비용·반출 | OIDC 연합·로컬 모델·자체 호스팅 대안, Usage & Cost 예산 |
| 라이선스(AGPL·ee·ELv2) 혼입 | 법적 리스크 | 8.4 정책, SBOM 경고 |
| 레지스트리 신뢰(악성 MCP 서버 등록) | 공급망 공격 | 승인 워크플로, 서명·출처 검증, 샌드박스·스코프 최소화 |

# 부록 A. 용어집

| 용어 | 설명 |
|---|---|
| MCP (Model Context Protocol) | LLM 앱(Host/Client)과 도구·리소스·프롬프트 서버 간 JSON-RPC 표준. 전송: stdio, Streamable HTTP |
| MCP Host / Client / Server | Host는 클라이언트 세션을 관리하는 앱, Client는 서버와 1:1 연결, Server는 도구 제공자 |
| A2A (Agent2Agent) | 에이전트 간 협업 프로토콜. Agent Card로 발견, Message/Task로 협업, Streaming·Artifacts |
| Agent Card | /.well-known/agent-card.json – 에이전트 이름·스킬·엔드포인트·보안 스킴 |
| AI Gateway | 모델·도구·에이전트 호출을 단일 지점에서 라우팅·보안·정책·관측하는 프록시 |
| Unified Model API | 다수 LLM 공급자를 하나의(OpenAI 호환) API로 추상화 |
| Tool & Agent Governance | 도구·에이전트 허용목록·인자 검증·승인·감사 |
| MCP Registry (server.json) | MCP 서버 메타데이터 발견 서비스. 실행 트래픽 미경유(Discovery only) |
| Token Exchange / OBO | 사용자 토큰을 대상 서비스용 최소 스코프 토큰으로 교환(RFC 8693) |
| MCP Authorization | 원격 MCP 서버 인증 사양(OAuth 2.1, RFC 9728 Protected Resource Metadata) |
| Replay & Audit | 세션 프롬프트·도구 호출·응답 재생과 불변 감사 로그 |

# 부록 B. 오픈소스·사양 출처·라이선스 총람

Star 수·라이선스: 2026-09-16 GitHub REST API 조회값. NOASSERTION은 LICENSE 원문 확인 후 기재. 개명·이전 저장소는 현재 이름(구 이름 병기).

| 도구 | URL | Star | 라이선스 |
|---|---|---|---|
| MCP Python SDK | https://github.com/modelcontextprotocol/python-sdk | 24,307 | MIT (Apache-2.0 전환 진행 중, LICENSE) |
| MCP TypeScript SDK | https://github.com/modelcontextprotocol/typescript-sdk | 13,404 | MIT (Apache-2.0 전환 진행 중) |
| MCP 참조 서버 | https://github.com/modelcontextprotocol/servers | 90,368 | MIT (Apache-2.0 전환 진행 중) |
| MCP Inspector | https://github.com/modelcontextprotocol/inspector | 10,884 | MIT (저장소 LICENSE 확인) |
| FastMCP | https://github.com/PrefectHQ/fastmcp | 27,682 | Apache-2.0 |
| fastapi_mcp | https://github.com/tadata-org/fastapi_mcp | 12,009 | MIT |
| mcp-use | https://github.com/mcp-use/mcp-use | 10,627 | MIT |
| mcp-agent | https://github.com/lastmile-ai/mcp-agent | 8,544 | Apache-2.0 |
| A2A 프로토콜 | https://github.com/a2aproject/A2A | 25,785 | Apache-2.0 |
| a2a-python | https://github.com/a2aproject/a2a-python | 2,141 | Apache-2.0 |
| a2a-js | https://github.com/a2aproject/a2a-js | 617 | Apache-2.0 |
| a2a-samples | https://github.com/a2aproject/a2a-samples | 1,765 | Apache-2.0 |
| Google ADK | https://github.com/google/adk-python | 21,546 | Apache-2.0 |
| OpenAI Agents SDK | https://github.com/openai/openai-agents-python | 29,466 | MIT |
| Microsoft Agent Framework | https://github.com/microsoft/agent-framework | 13,536 | MIT |
| LangGraph | https://github.com/langchain-ai/langgraph | 41,713 | MIT |
| CrewAI | https://github.com/crewAIInc/crewAI | 58,621 | MIT |
| AutoGen | https://github.com/microsoft/autogen | 61,001 | MIT (코드) / CC-BY-4.0 (문서) |
| PydanticAI | https://github.com/pydantic/pydantic-ai | 19,967 | MIT |
| LiteLLM | https://github.com/BerriAI/litellm | 58,820 | MIT (enterprise/ 별도) |
| Portkey Gateway | https://github.com/Portkey-AI/gateway | 13,003 | MIT |
| Bifrost | https://github.com/maximhq/bifrost | 8,099 | Apache-2.0 |
| Plano | https://github.com/katanemo/plano | 7,051 | Apache-2.0 |
| TensorZero | https://github.com/tensorzero/tensorzero | 11,720 | Apache-2.0 |
| Higress | https://github.com/higress-group/higress | 9,389 | Apache-2.0 |
| Apache APISIX | https://github.com/apache/apisix | 17,125 | Apache-2.0 |
| Kong | https://github.com/Kong/kong | 44,141 | Apache-2.0 |
| agentgateway | https://github.com/agentgateway/agentgateway | 4,869 | Apache-2.0 |
| kgateway | https://github.com/kgateway-dev/kgateway | 5,689 | Apache-2.0 |
| Envoy AI Gateway (agent-router) | https://github.com/theagentrouter/agent-router | 2,099 | Apache-2.0 |
| MCP Context Forge | https://github.com/IBM/mcp-context-forge | 4,477 | Apache-2.0 |
| MCP Gateway (Lasso) | https://github.com/lasso-security/mcp-gateway | 387 | MIT |
| Agent Governance Toolkit | https://github.com/microsoft/agent-governance-toolkit | 6,268 | MIT |

| | | | |
|---|---|---|---|
| OPA | https://github.com/open-policy-agent/opa | 12,238 | Apache-2.0 |
| MCP Registry (공식) | https://github.com/modelcontextprotocol/registry | 7,254 | MIT (Apache-2.0 전환 진행 중) |
| Docker MCP Registry | https://github.com/docker/mcp-registry | 554 | MIT |
| awesome-mcp-servers | https://github.com/punkpeye/awesome-mcp-servers | 95,055 | MIT |
| OpenAI SDK | https://github.com/openai/openai-python | 31,626 | Apache-2.0 |
| Anthropic SDK | https://github.com/anthropics/anthropic-sdk-python | 3,902 | MIT |
| Google GenAI SDK | https://github.com/googleapis/python-genai | 3,978 | Apache-2.0 |
| vLLM | https://github.com/vllm-project/vllm | 91,866 | Apache-2.0 |
| Ollama | https://github.com/ollama/ollama | 181,079 | MIT |
| Keycloak | https://github.com/keycloak/keycloak | 36,793 | Apache-2.0 |
| Ory Hydra | https://github.com/ory/hydra | 17,543 | Apache-2.0 |
| Authlib | https://github.com/authlib/authlib | 5,422 | BSD-3-Clause |
| MSAL for Python | https://github.com/AzureAD/microsoft-authentication-library-for-python | 972 | MIT |
| Okta SDK | https://github.com/okta/okta-sdk-python | 270 | Apache-2.0 |
| OpenTelemetry | https://github.com/open-telemetry/opentelemetry-python | 2,633 | Apache-2.0 |
| OpenLLMetry | https://github.com/traceloop/openllmetry | 7,430 | Apache-2.0 |
| OpenLIT | https://github.com/openlit/openlit | 2,768 | Apache-2.0 |
| Jaeger | https://github.com/jaegertracing/jaeger | 23,211 | Apache-2.0 |
| Prometheus | https://github.com/prometheus/prometheus | 66,081 | Apache-2.0 |
| Grafana | https://github.com/grafana/grafana | 76,766 | AGPL-3.0 |
| Langfuse | https://github.com/langfuse/langfuse | 34,654 | MIT (ee/ 별도) |
| Helicone | https://github.com/Helicone/helicone | 6,159 | Apache-2.0 |
| Arize Phoenix | https://github.com/Arize-ai/phoenix | 11,474 | Elastic License 2.0 |
| Opik | https://github.com/comet-ml/opik | 22,046 | Apache-2.0 |
| mcp-atlassian | https://github.com/sooperset/mcp-atlassian | 5,906 | MIT |
| Dynatrace MCP | https://github.com/dynatrace-oss/dynatrace-mcp | 136 | MIT |
| GitHub MCP Server | https://github.com/github/github-mcp-server | 32,956 | MIT |
| AWS MCP Servers | https://github.com/awslabs/mcp | 9,696 | Apache-2.0 |
| FastAPI | https://github.com/fastapi/fastapi | 102,354 | MIT |
| Valkey | https://github.com/valkey-io/valkey | 27,207 | BSD-3-Clause |
| Temporal | https://github.com/temporalio/temporal | 23,069 | MIT |

### 사양·표준

- Model Context Protocol 사양(Architecture, Transports: Streamable HTTP, Authorization, Registry) – https://modelcontextprotocol.io/specification · https://registry.modelcontextprotocol.io
- A2A Protocol 사양 — https://a2a-protocol.org (Agent Card, Task lifecycle, message/send·stream, Push Notifications)
- OAuth 2.1 draft, RFC 9728 Protected Resource Metadata, RFC 8693 Token Exchange, RFC 8414 AS Metadata – https://www.rfc-editor.org
- OpenAI API Reference(호환 API 기준) – https://platform.openai.com/docs/api-reference

- OpenTelemetry GenAI Semantic Conventions – https://opentelemetry.io/docs/specs/semconv/gen-ai/
- W3C Trace Context – https://www.w3.org/TR/trace-context/
- OWASP Agentic AI – Threats and Mitigations – https://genai.owasp.org
- Kubernetes Gateway API – https://gateway-api.sigs.k8s.io

# 부록 C. WisemanLim Star 목록 중 참고 저장소

출처: https://github.com/WisemanLim?tab=stars – 2026-09-16 GitHub REST API(users/WisemanLim/starred) 전체 5,826건 조회. C.1은 8.1 카탈로그와 일치(★ 35종), C.2는 추가 관련 저장소.

### C.1 카탈로그 일치(★)

A2A 프로토콜, AWS MCP Servers, Agent Governance Toolkit, Arize Phoenix, AutoGen, Bifrost, CrewAI, FastAPI, FastMCP, GitHub MCP Server, Google GenAI SDK, Grafana, Helicone, Jaeger, Keycloak, LangGraph, LiteLLM, MCP Inspector, MCP Python SDK, MCP 참조 서버, Ollama, OpenAI Agents SDK, OpenAI SDK, Opik, Plano, Portkey Gateway, Prometheus, PydanticAI, TensorZero, awesome-mcp-servers, fastapi_mcp, mcp-agent, mcp-atlassian, mcp-use, vLLM

### C.2 추가 관련 저장소

| 저장소 | Star | 라이선스 | 본 시스템 관련성 |
|---|---|---|---|
| diegosouzapw/OmniRoute | 66,242 | MIT | 무료 AI 게이트웨이(352 공급자 단일 엔드포인트) – Unified Model API 참고 |
| makeplane/plane | 59,401 | AGPL-3.0 | Jira 대안(자체 호스팅) – Jira MCP 백엔드 대체(AGPL) |
| danny-avila/LibreChat | 43,570 | MIT | MCP·에이전트 지원 채팅 UI – Natural language 진입 UI 참고 |
| microsoft/playwright-mcp | 37,114 | Apache-2.0 | 공식 MCP 서버 구현 패턴 |
| goharbor/harbor | 29,368 | Apache-2.0 | 컨테이너 레지스트리(MCP 서버 이미지 서명·스캔) |
| activepieces/activepieces | 24,450 | 기타(확인 필요) | 400+ MCP 서버 워크플로 자동화 |
| microsoft/mcp-for-beginners | 17,213 | MIT | MCP 교육 자료 |
| googleapis/mcp-toolbox | 16,403 | Apache-2.0 | DB용 MCP 서버(Internal System 연동 참고) |
| Untrivial-ai/agent-orchestrator | 12,043 | Apache-2.0 | 코딩 에이전트 팀 오케스트레이션(연계 참고) |
| google/adk-samples | 10,313 | Apache-2.0 | ADK 샘플(A2A·MCP 조합) |
| evidentlyai/evidently | 7,914 | Apache-2.0 | ML·LLM 관측·평가 |
| Klavis-AI/klavis | 5,803 | Apache-2.0 | MCP 통합 플랫폼(호스팅 MCP 서버·인증) |
| oomol-lab/open-connector | 5,743 | Apache-2.0 | 1500+ SaaS 인증 게이트웨이(MCP 서버 Auth 참고) |
| appcypher/awesome-mcp-servers | 5,769 | 기타(확인 필요) | MCP 서버 큐레이션 |
| grafana/tempo | 5,473 | AGPL-3.0 | 트레이싱 백엔드(Jaeger 대안, AGPL) |
| looplj/axonhub | 5,226 | 기타(확인 필요) | 오픈소스 AI 게이트웨이(폴백·라우팅) |
| lastmile-ai/mcp-agent | 8,544 | Apache-2.0 | MCP 기반 에이전트 워크플로(카탈로그 포함) |
| mcp-use/mcp-use | 10,627 | MIT | MCP 앱 풀스택 프레임워크(카탈로그 포함) |

# 부록 D. 참고 이미지 출처

| 그림 | 설명 | 출처 / 저작자 | 사용 방식 |
|---|---|---|---|
| 원본 첨부 이미지 | 「MCP + AI Gateway + A2A」 아키텍처 인포그래픽: User →Agent Application/MCP Host(Planner·Retriever·Summarize·Executor, MCP Client Layer, A2A Client) →AI Gateway(7기능) ↔ LLM Providers(4) · Remote A2A Agent(5) · MCP Registry · Identity(Entra ID·Okta) · Observability & Audit(5) · MCP Servers(5)+백엔드(5), 엣지 라벨 13 | 작성자: Alok Sharan (@alok-sharan – 이미지 내 표기). 사용자가 본 PRD 작성 요청 시 첨부. 원 게시 URL 미확인 | 내용 분석의 기준 명세로 사용. 원본 이미지는 본 문서에 삽입하지 않고 재구성 도식(그림 1)으로 대체. 원본 저작권은 저작자에 귀속 |
| 그림 1 | 기준 도식 재구성(11그룹·44컴포넌트·엣지 라벨) | 본 문서 작성(Mermaid block-beta / mermaid-cli) | 원본 항목 1:1 반영(3.3 추적표) |
| 그림 2 | AgentNexus 6계층 아키텍처 | 본 문서 작성(Mermaid block-beta) | 설계 산출물 |

## 부록 E. 조사 방법 및 한계

- **저장소 확정:** 도식 11그룹 대응 오픈소스 62건을 선정, GitHub REST API repos/{owner}/{repo}로 Star·라이선스 조회(2026-09-16). 리다이렉트된 저장소는 현재 이름 사용.
- **라이선스 원문 확인:** NOASSERTION 6건 LICENSE 본문 확인. MCP 조직 저장소(python-sdk·typescript-sdk·servers·registry)는 'MIT → Apache-2.0 전환 진행 중' 문구 — 채택 시점 재확인.
- **Star 목록 교차:** users/WisemanLim/starred 전체 5,826건과 저장소 이름 정확 일치(35종) + 키워드(mcp, a2a, gateway, registry, observability, orchestration 등) 검색으로 추가 18건.
- **한계:** (1) 원본 이미지 게시 URL 미확인. (2) 도식 좌측 보라 점선 'Access Token'의 정확한 양단은 이미지상 모호하여 '클라이언트 토큰 전달'로 해석(3.1). (3) 상용 SaaS는 SDK 저장소로 대표. (4) NFR 수치는 초안. (5) MCP·A2A 사양 진화 빠름 — 버전 고정 필요.
- **문서 생성:** python-docx 1.2.0 → DOCX, LibreOffice(soffice --headless) → PDF.